### PHÂN TÍCH LUÒNG DỮ LIỆU LỚN VỚI KAFKA & SPARK

Giảng viên: TS. Nguyễn Văn Quyết



#### Nội dung

- Giới thiệu chung về Kafka
- Một số khái niệm cơ bản trong Kafka
- Kiến trúc của Kafka
- Kafka Workflow
- Thực hành với Kafka
- Hỏi & đáp

2/46

#### What is Kafka?

- Apache Kafka là một hệt thống message pub/sub (distributed publish-subscribe messaging system) và có khả năng truyền một lượng lớn các message theo thời gian thực.
- Kafka messages được lưu trữ trên ổ đĩa và được nhân bản trên cụm để phòng trách việc mất dữ liệu.
- Kafka được "built on top of the ZooKeeper".
- http://kafka.apache.org/



#### Tại sao nên sử dụng Kafka?

- Tin cậy (Reliability): phân tán, phân mảnh, sao lưu và khả năng chịu lỗi
- Khả năng mở rộng (Scalibility): mở rộng theo chiều ngang.
- Tính an toàn (Duribility): dữ liệu được lưu trữ an toàn cho đến khi bên nhận sẵn sàng nhận nó.
- Hiệu năng (Performance): Kafka thích hợp cho việc xử lý dòng dữ liệu thời gian thực với thông lượng cao cho cả hoạt động pub/sub messages.

#### Kafka Usecases

- Messaging
- Website Activity Tracking
- Metrics
- Log Aggregation
- Stream Processing
- Commit Log

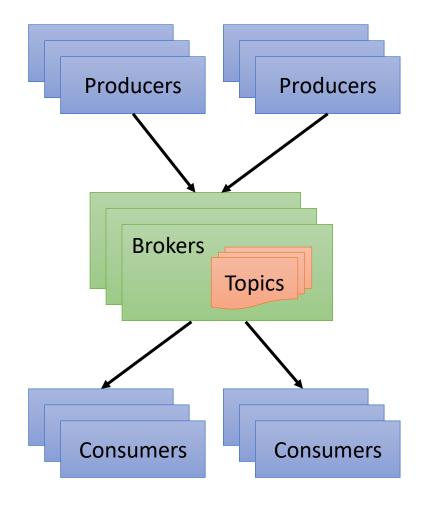
#### Các khái niệm cơ bản

- A first look
- Topics, partitions, offsets, replicas
- Brokers, producers, consumers
- Putting it all together

#### A first look

- Producers ghi dữ liệu tới các brokers.
- Dữ liệu được lưu trong các topics.
- Consumers đọc dữ liệu từ các brokers.

#### **Apache Kafka**



#### Topics (1/5)

- Một topic là một chủ đề mà các bản ghi (dữ liệu) được đưa vào để publish.
- Một topic trong Kafka có thể có nhiều subcriber
- Một topic có thể được chia làm nhiều partitions

#### **Topic 1**

Partition 1

0 1 2

Partition 2

0 1 2 3

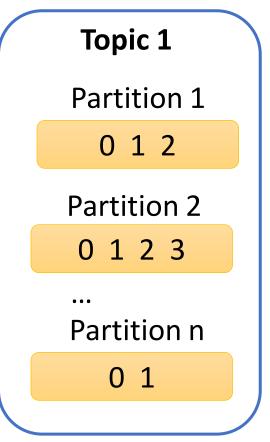
• • •

Partition n

0 1

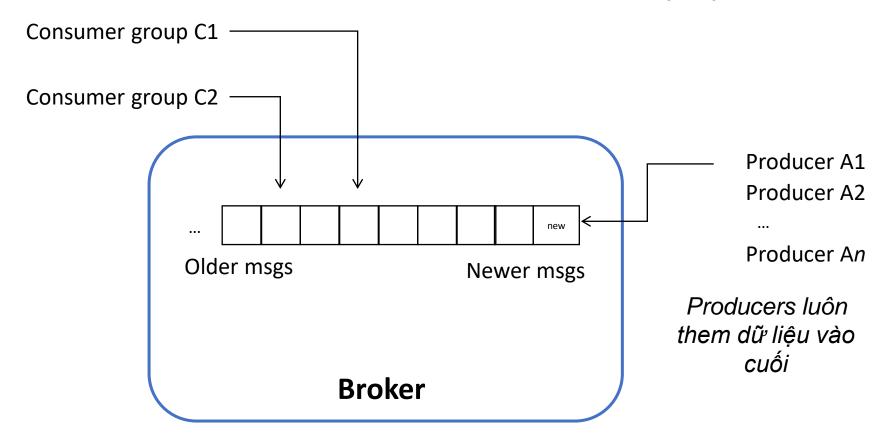
#### Topics (2/5)

- Partitions: chứa các messages được sắp xếp tuần tự không thay đổi được. Nó được thiết lập là tập các file có kích thước bằng nhau.
- Mỗi partition có một ID duy nhất gọi là partition offset.



#### Topics (3/5)

Consumers sử dụng một "offset pointer" để theo dõi và điều khiển việc đọc của nó



#### Topics (4/5)

- Replicas: bản sao lưu của một partition
  - Nó được sử dụng để phòng tránh việc mất dữ liệu.
  - Nó KHÔNG trợ giúp các producer hoặc consumer trong việc song song hóa!
  - Kafka có khả năng thay thế các "dead brokers" (numReplicas 1)
    - LinkedIn: numReplicas == 2 → 1 broker có thể hỏng

#### Topics (5/5)

- Mỗi partition có một server (node) giữ vai trò làm "leader" và có thể có 0 hoặc nhiều "followers".
- Leader: là node chịu trách nhiệm đọc và ghi dữ liệu trên một partition nó.
  - Every partition has one server acting as a leader.
- Follower: là node hoạt động theo chỉ dẫn của leader
  - N\u00e9u leader fails, m\u00f6t follower s\u00e9 du\u00f6c t\u00fc d\u00f6ng ch\u00f6n l\u00e4m leader.

#### **Brokers**

- - Mỗi broker có thể có 0 hoặc nhiều partitions / topic.

Topic: Topic 1

Partitions: 1 Replicas: 3

Topic: Topic 2

Partitions: 2 Replicas: 2 **Broker 1** 

Leader

Topic 1 – Partition 1

Follower

Topic 2 – Partition 1

Follower

Topic 2 – Partition 2

Replicas 1

**Broker 2** 

Follower

Topic 1 – Partition 1

Leader

Topic 2 – Partition 1

Replicas 2

**Broker 3** 

**Follower** 

Topic 1 – Partition 1

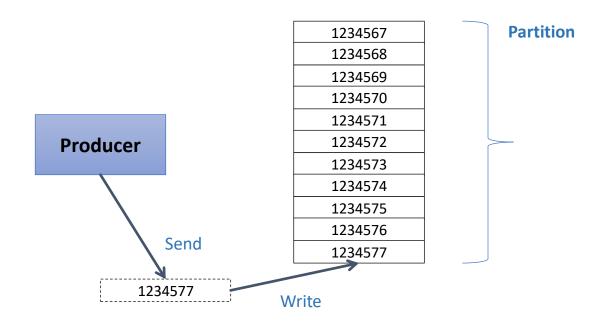
Leader

Topic 2 – Partition 2

Replicas 3

#### **Producers**

- Producers: đưa các messages to một hoặc nhiều Kafka topics.
  - Producers gửi dữ liệu tới các Kafka brokers.
  - Broker ghi nối tiếp các message vào cuối mỗi segment file.
  - Producer gửi các messages tới một partition mà nó chọn.

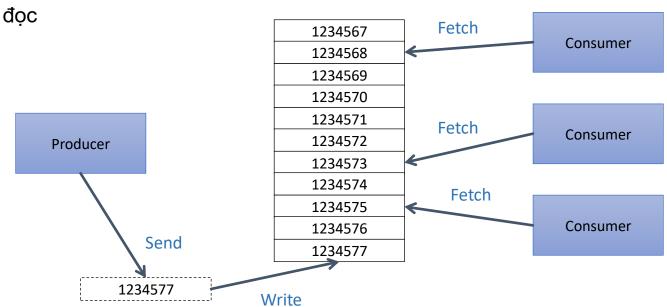


Nguyễn Văn Quyết Al Academy Vietnam 02-05-2022 14/46

#### Consumers

- Consumers đọc dữ liệu từ brokers
- Consumers đăng ký nhận/đọc dữ liệu từ một hoặc nhiều topics
  - Nhiều consumers có thể đọc dữ liệu trên cùng topic
  - Mỗi consumer chịu trách nhiệm quản lý các địa chỉ offset mà

Các messages được lưu giữ trong Kafka...chúng không bị xóa sau khi được



#### Consumers - Group

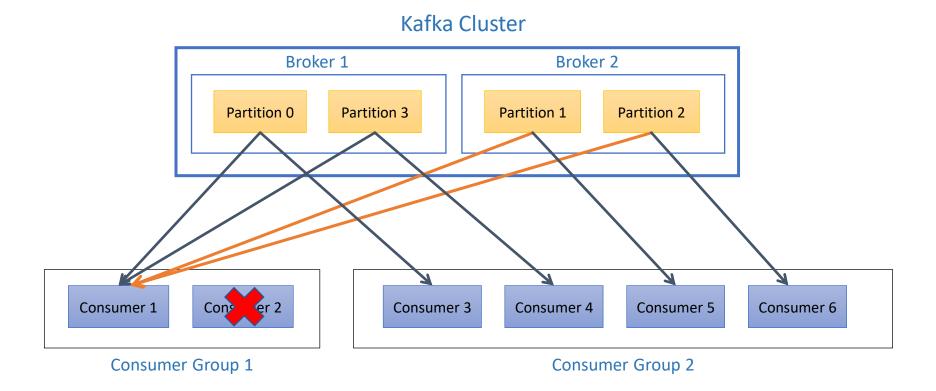
- Consumers có thể được tổ chức thành nhóm
- Common Patterns:
  - Tất cả các comsumer trong các nhóm khác nhau
  - Nhiều consumer trong một nhóm
    - 。 Các Consumers được thêm vào để tang khả năng mở rộng và chịu lỗi
    - 。 Mỗi consumer đọc từ một hoặc nhiều partitions của một topic
    - 。 Số Consumer một nhóm không nhiều hơn số partitions

#### Consumers - Group

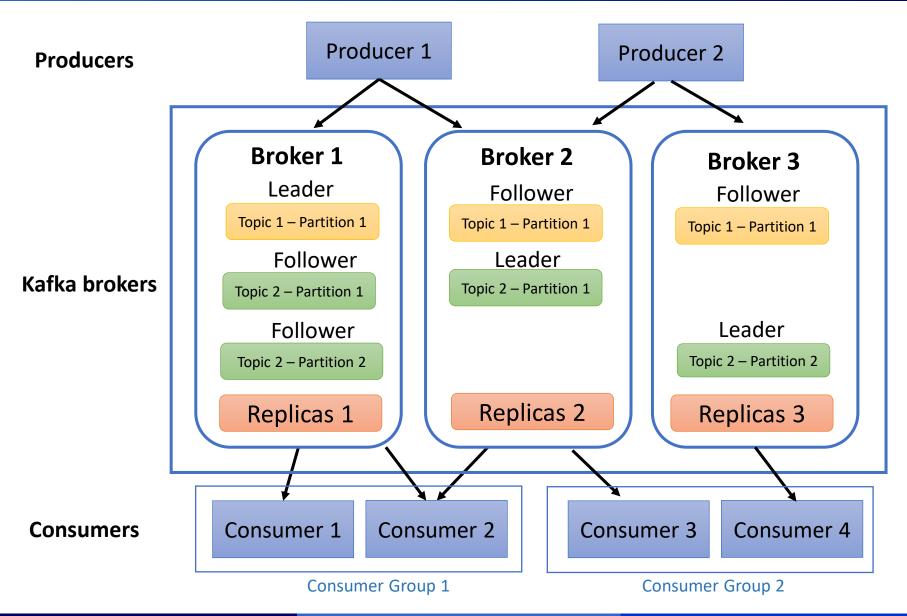
#### Kafka Cluster Broker 1 **Broker 2** Partition 3 Partition 0 Partition 1 Partition 2 Consumer 1 Consumer 2 Consumer 3 Consumer 4 Consumer 5 Consumer 6 Consumer Group 1 Consumer Group 2

Nguyễn Văn Quyết Al Academy Vietnam 02-05-2022 17/46

#### Consumers - Group

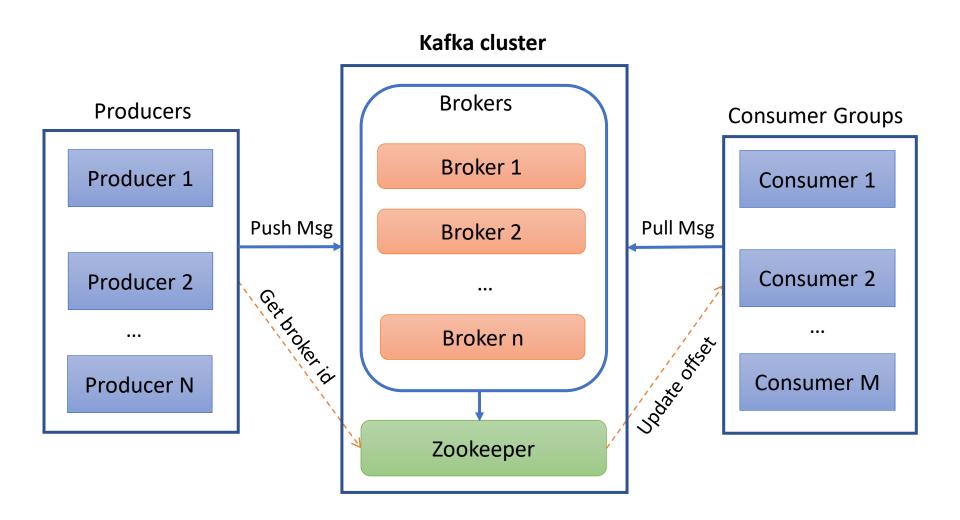


#### Put it all together



19/46

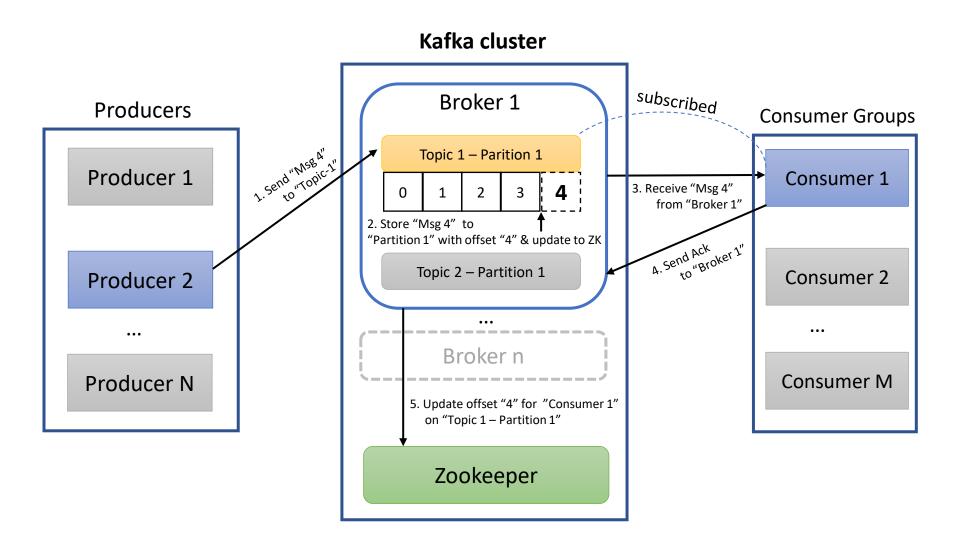
#### Kiến trúc của Kafka



#### Vai trò của Zookeeper

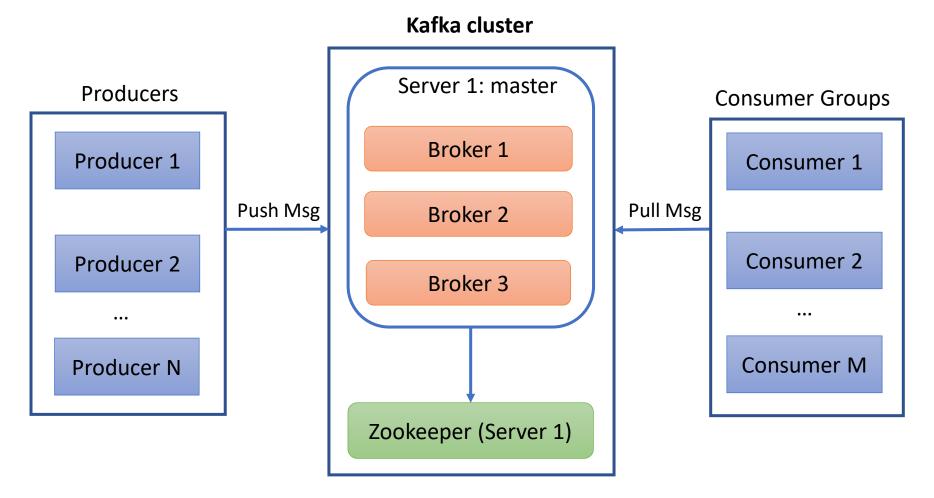
- ZooKeeper được sử dụng để thông báo cho producer và consumer về sự có mặt của bất kỳ new broker hoặc lỗi xảy ra trên broker trong hệ thống.
- Zookeeper dùng để lưu trữ thông tin metadata của Kafka như về topics, brokers, và consumer offsets.
- Lựa chọn leader giữa các Kafka brokers trong khi một broker bị
   lỗi.

#### Kafka Workflow



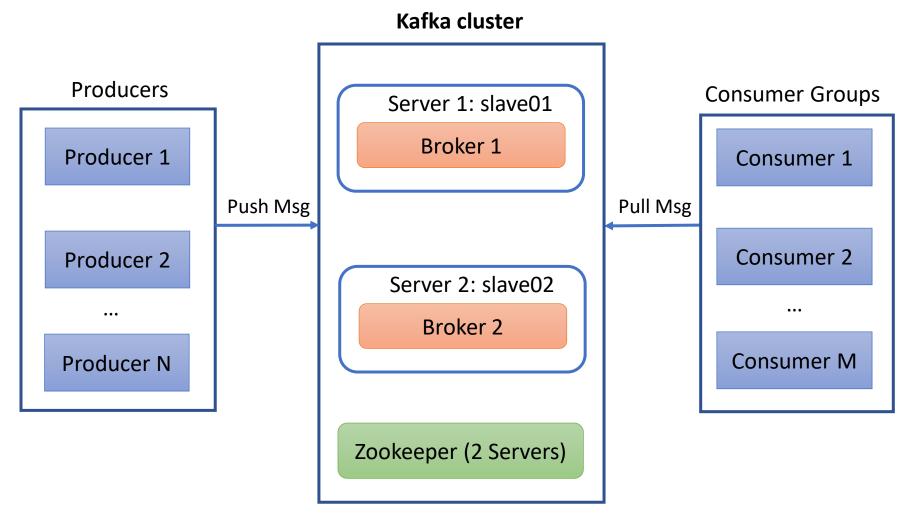
# Chuẩn bị môi trường – Kiến trúc hệ thống

Multi Brokers on Single Node



# Chuẩn bị môi trường – Kiến trúc hệ thống

Multi Brokers on Multi Nodes → Dùng trong bài thực hành



Bước 1: Tải và cài đặt Zookeeper (trên máy master)

hduser@master:/usr/local\$ sudo chown -R hduser:hadoop zookeeper

hduser@master:~\$ cd /usr/local \$ sudo wget http://apache.tt.co.kr/zookeeper/stable/apache-zookeeper-3.6.3-bin.tar.gz hduser@master:/usr/local\$ sudo tar -xzvf apache-zookeeper-3.6.3-bin.tar.gz hduser@master:/usr/local\$ sudo mv apache-zookeeper-3.6.3-bin zookeeper

Nguyễn Văn Quyết Al Academy Vietnam 02-05-2022 25/46

- Bước 2: Thiết lập biến môi trường cho Zookeeper (trên tất cả các máy)
  - Thêm vào file ~/.bashrc các lệnh sau:

```
# Set Zookeeper related variables
export ZOOKEEPER_HOME="/usr/local/zookeeper"

# Add Zookeeper bin/ directory to PATH
export PATH=$PATH:$ZOOKEEPER_HOME/bin
```

Chạy lệnh sau để áp dụng

\$ source ~/.bashrc

 Bước 3: Tạo thư mục lưu dữ liệu của Zookeeper (trên tất cả các máy)

```
hduser@master:~$ sudo mkdir -p /app/zookeeper/data
hduser@master:~$ sudo chown -R hduser:hadoop /app/zookeeper/
```

```
hduser@slave01:~$ sudo mkdir -p /app/zookeeper/data
hduser@slave01:~$ sudo chown -R hduser:hadoop /app/zookeeper/
```

hduser@slave02:~\$ sudo mkdir -p /app/zookeeper/data hduser@slave02:~\$ sudo chown -R hduser:hadoop /app/zookeeper/

- Bước 4: Cấu hình Zookeeper
  - Cấu hình file zoo.cfg (trên máy master)

hduser@master:~\$ cd /usr/local/zookeeper hduser@master:/usr/local/zookeeper\$ cp conf/zoo\_sample.cfg conf/zoo.cfg hduser@master:/usr/local/zookeeper\$ sudo gedit conf/zoo.cfg

// Sửa đường dẫn trỏ đến thư mục chưa dữ liệu của Zookeeper trong tệp dataDir=/app/zookeeper/data

Bước 5: Copy Zookeeper từ master sang các slaves (1/2) // Tạo và cấp quyền thư mục zookeeper trên máy slave01

hduser@master:~\$ ssh slave01

hduser@slave01:~\$ sudo mkdir /usr/local/zookeeper

hduser@slave01:~\$ sudo chown -R hduser:hadoop /usr/local/zookeeper

hduser@slave01:~\$ exit

// Tạo và cấp quyền thư mục zookeeper trên máy slave02

hduser@master:~\$ ssh slave02

hduser@slave02:~\$ sudo mkdir /usr/local/zookeeper

hduser@slave02:~\$ sudo chown -R hduser:hadoop /usr/local/zookeeper

hduser@slave02:~\$ exit

Bước 5: Copy Zookeeper từ master sang các slaves (2/2)

```
// Copy thư mục Hbase từ máy master sang các máy slaves
hduser@master:~$ scp -r /usr/local/zookeeper/*
hduser@slave01:/usr/local/zookeeper/
hduser@master:~$ scp -r /usr/local/zookeeper/*
hduser@slave02:/usr/local/zookeeper/
```

- Bước 6: Khởi chạy Zookeeper
  - Chay Zookeeper:

hduser@master:~\$ cd /usr/local/zookeeper hduser@master:/usr/local/zookeeper\$ bin/zkServer.sh start

```
hduser@master:/usr/local/zookeeper$ bin/zkServer.sh start
ZooKeeper JMX enabled by default
Using config: /usr/local/zookeeper/bin/../conf/zoo.cfg
Starting zookeeper ... STARTED
hduser@master:/usr/local/zookeeper$ jps
3187 QuorumPeerMain
3221 Jps
hduser@master:/usr/local/zookeeper$
```

Bước 1: Tải và cài đặt Kafka

hduser@master:~\$ cd /usr/local

hduser@master:/usr/local\$ sudo wget

https://downloads.apache.org/kafka/2.8.0/kafka\_2.12-2.8.0.tgz

hduser@master:/usr/local\$ sudo tar -xzvf kafka\_2.12-2.8.0.tgz

hduser@master:/usr/local\$ sudo mv kafka\_2.12-2.8.0.tgz kafka

hduser@master:/usr/local\$ sudo chown -R hduser:hadoop kafka

- Bước 2: Thiết lập biến môi trường cho Kafka (trên tất cả các máy)
  - Thêm vào file ~/.bashrc các lệnh sau:

```
# Set Kafka related variables
export KAFKA_HOME="/usr/local/kafka"

# Add Kafka bin/ directory to PATH
export PATH=$PATH:$KAFKA_HOME/bin
```

Chạy lệnh sau để áp dụng

\$ source ~/.bashrc

Bước 3: Copy Kafka từ master sang các slaves (1/2)

// Tạo và cấp quyền thư mục kafka trên máy slave01

hduser@master:~\$ ssh slave01

hduser@slave01:~\$ sudo mkdir /usr/local/kafka

hduser@slave01:~\$ sudo chown -R hduser:hadoop /usr/local/kafka

hduser@slave01:~\$ exit

// Tạo và cấp quyền thư mục kafka trên máy slave02

hduser@master:~\$ ssh slave02

hduser@slave02:~\$ sudo mkdir /usr/local/kafka

hduser@slave02:~\$ sudo chown -R hduser:hadoop /usr/local/kafka

hduser@slave01:~\$ exit

Bước 3: Copy Kafka từ master sang các slaves (2/2)

// Copy thư mục Hbase từ máy master sang các máy slaves

hduser@master:~\$ scp -r /usr/local/kafka/\* hduser@slave01:/usr/local/kafka

hduser@master:~\$ scp -r /usr/local/kafka/\* hduser@slave02:/usr/local/kafka

- Bước 4: Cấu hình Kafka trên các máy slaves (1/3)
  - Multi Brokers on Multi Nodes (tao 2 Brokers trên 2 nodes)

```
// Trên máy Slave01
```

hduser@slave01:~\$ cd /usr/local/kafka

hduser@slave01:/usr/local/kafka\$ cp config/server.properties config/slave01-1.properties

```
// Trên máy Slave02
```

hduser@slave02:~\$ cd /usr/local/kafka

hduser@slave02:/usr/local/kafka\$ cp config/server.properties config/slave02-1.properties

- Bước 4: Cấu hình Kafka trên các máy slaves (2/3)
  - Kiểm tra sửa/thêm vào các cấu hình sau

```
// Trên máy Slave01
```

hduser@slave01:/usr/local/kafka\$ sudo gedit config/slave01-1.properties

- broker.id=1
- port=9092
- log.dirs=/tmp/kafka/slave01-1-logs
- host.name=10.0.2.196
- zookeeper.connect= 10.0.2.196:2181, 10.0.2.197:2181

- Bước 4: Cấu hình Kafka trên các máy slaves (3/3)
  - Kiểm tra sửa/thêm vào các cấu hình sau

// Trên máy Slave02

hduser@slave02:/usr/local/kafka\$ sudo gedit config/slave02-1.properties

- broker.id=2
- port=9093
- log.dirs=/tmp/kafka/slave02-1-logs
- host.name=10.0.2.197
- zookeeper.connect= 10.0.2.196:2181, 10.0.2.197:2181

Bước 5: Khởi chạy Zookeeper trên các slaves

```
// Trên máy Slave01
hduser@slave01:~$ cd /usr/local/zookeeper
hduser@slave01:/usr/local/zookeeper$ bin/zkServer.sh start
hduser@slave01:/usr/local/zookeeper$ bin/zkCli.sh -server 10.0.2.196:2181
```

```
// Trên máy Slave02
```

hduser@slave02:~\$ cd /usr/local/zookeeper

hduser@slave02:/usr/local/zookeeper\$ bin/zkServer.sh start

hduser@slave02:/usr/local/zookeeper\$ bin/zkCli.sh -server 10.0.2.197:2181

Bước 6: Chạy Kafka server trên các slaves

```
// Trên máy Slave01
hduser@slave01:~$ cd /usr/local/kafka
hduser@slave01:/usr/local/kafka$ ./bin/kafka-server-start.sh -daemon
config/slave01-1.properties

// Trên máy Slave02
hduser@slave02:~$ cd /usr/local/kafka
hduser@slave02:/usr/local/kafka$ ./bin/kafka-server-start.sh -daemon
config/slave02-1.properties
```

Bước 7: Kiểm tra Kafka server trên các slaves

```
// Trên máy Slave01
hduser@slave01:~$ jps
```

```
hduser@slave01:/usr/local$ cd kafka/
hduser@slave01:/usr/local/kafka$ bin/kafka-server-start.sh -daemon config/slave01-1.properties
hduser@slave01:/usr/local/kafka$ jps
2304 ZooKeeperMain
2712 Jps
2267 QuorumPeerMain
2685 Kafka
hduser@slave01:/usr/local/kafka$
```

// Tương tự, kiểm tra Kafka trên máy Slave02

```
hduser@slave02:/usr/local/kafka$ jps
2114 QuorumPeerMain
7763 Kafka
8166 Jps
4620 ZooKeeperMain
hduser@slave02:/usr/local/kafka$
```

Bước 1: Tạo topics

```
// Trên máy Slave01
hduser@slave01:~$ cd /usr/local/kafka
hduser@slave01:/usr/local/kafka$ ./bin/kafka-topics.sh --zookeeper
10.0.2.196:2181,10.0.2.197:2181 --create --topic weather --replication-factor
1 --partitions 1
```

```
hduser@slave01:/usr/local/kafka$ ./bin/kafka-topics.sh --zookeeper 10.0.2.196:2181,10.0.2.197
:2181 --create --topic weather --replication-factor 1 --partitions 1
Created topic weather.
```

Bước 2: Xem thông tin topic

```
// Trên máy Slave01
hduser@slave01:~$ cd /usr/local/kafka
hduser@slave01:/usr/local/kafka$ ./bin/kafka-topics.sh --zookeeper
10.0.2.196:2181,10.0.2.197:2181 --describe --topic weather
```

Bước 3: Chạy một producer

```
// Trên máy Slave01
hduser@slave01:~$ cd /usr/local/kafka
hduser@slave01:/usr/local/kafka$ ./bin/kafka-console-producer.sh --broker-list 10.0.2.196:9092,10.0.2.197:9093 --topic weather
```

```
hduser@slave01:/usr/local/kafka$ kafka-console-producer.sh --broker-list
10.0.2.196:9092,10.0.2.197:9093 --topic weather
>21
>23
>
```

Bước 4: Chạy một consumer

```
// Trên máy Slave02
hduser@slave02:~$ cd /usr/local/kafka
hduser@slave02:/usr/local/kafka$ ./bin/kafka-console-consumer.sh --bootstrap-
server 10.0.2.196:9092,10.0.2.197:9093 --topic weather
```

```
hduser@slave02:/usr/local/kafka$ ./bin/kafka-console-consumer.sh --bootstrap-server 10.0.2.196:9092,10.0.2.197:9093 --topic weather --from-beginning 21 23
```

# Trân trọng cảm ơn! Q&A